

Desarrollo de aplicaciones avanzadas de ciencias computacionales

Fidel Alexander Bonilla Montlavo

Instituto Tecnológico y de Estudios Superiores de Monterrey

A01798199

Querétaro, México

9 junio de 2026

Resumen

Este trabajo clasifica emociones en perros a partir de imágenes: enojado, feliz, relajado o triste. Se usaron redes neuronales convolucionales con aprendizaje por transferencia y un dataset de unas 4 000 imágenes distribuidas en partes iguales entre las cuatro categorías.

Se compararon VGG16 y EfficientNetV2B0. El segundo modelo, entrenado con fine-tuning, callbacks y regularización, alcanzó el 67 % de precisión en prueba, lo que coincide con lo reportado en arquitecturas similares.

El aprendizaje por transferencia funcionó razonablemente bien con un dataset de tamaño moderado. La precisión puede subir trabajando el preprocesamiento y revisando los hiperparámetros.

1. Introducción

El comportamiento animal lleva décadas estudiándose y para detectar las emociones de las mascotas los perros son un buen punto de partida porque son expresivos: posturas, gestos faciales y conductas que los humanos aprendemos a interpretar sin mucho esfuerzo, pero que son difíciles de formalizar.

Las CNN abordan esa dificultad extrayendo representaciones visuales cada vez más abstractas sin que nadie tenga que definir las a mano. El aprendizaje por transferencia hace el proceso más accesible, en lugar de entrenar desde cero, se toma un modelo ya entrenado en millones de imágenes y se ajusta al problema específico.

Este trabajo compara dos arquitecturas, VGG16 y EfficientNetV2B0, para clasificar imágenes de perros en cuatro estados: angry, happy, relaxed y sad. El punto de referencia es el paper “CLASSIFICATION OF DOG EMOTIONS USING CONVOLUTIONAL NEURAL NETWORK METHOD” (2023), que trabajaron el mismo problema y alcanzaron el 74.75 % de precisión con una CNN personalizada.

El conjunto de datos utilizado fue obtenido de Kaggle bajo el nombre Dog Emotion Dataset. Este dataset está compuesto por imágenes de perros organizadas en cuatro categorías emocionales, con aproximadamente 1 000 imágenes por clase, lo que resulta en un total aproximado de 4 000 imágenes. La distribución balanceada entre clases es una propiedad especialmente conveniente, ya que evita sesgos en el proceso de entrenamiento derivados de la sobrerrepresentación de alguna categoría.

Las cuatro clases del dataset corresponden a las siguientes expresiones emocionales:

Etiqueta	Descripción emocional
angry	Perro enojado o agresivo
happy	Perro feliz o juguetón
relaxed	Perro relajado o tranquilo
sad	Perro triste o apático

Cada imagen muestra a un perro en condiciones variables de iluminación, encuadre, raza y fondo. Esta variabilidad, si bien incrementa la dificultad del problema, también favorece la capacidad de generalización del modelo una vez entrenado adecuadamente.


2. Descripción del Conjunto de Datos

Total de imágenes → 4,000


Total de Clases → 4

Total de Imágenes por clase

- angry - 1000
- happy - 1000
- relaxed - 1000
- sad - 1000



Como vemos las clases están bien distribuidas para eso se separará así



3. Preparación de los Datos

3.1 Partición del Conjunto de Datos

El dataset original únicamente organiza las imágenes por clase, sin una partición predefinida para entrenamiento, validación y prueba. Para garantizar una evaluación rigurosa del modelo, se realizó una partición estratificada aleatoria con la siguiente distribución:

Partición	Porcentaje	Imágenes por clase (aprox.)	Total (4 clases)
Entrenamiento	70 %	700	2 800
Validación	15 %	150	600
Prueba	15 %	150	600

El proceso de partición consiste en listar las imágenes de cada clase, aplicar una permutación aleatoria, dividir según los porcentajes indicados, y copiar cada subconjunto a una carpeta independiente con la estructura requerida por los generadores de imágenes de Keras. Este procedimiento garantiza que no exista contaminación entre conjuntos, preservando la validez de la evaluación final.

3.2 Preprocesamiento y Aumento de Datos

El preprocesamiento estándar aplicado a todas las particiones consiste en la normalización de los valores de píxel del rango [0, 255] al rango [0, 1], mediante la división por 255. Esta normalización facilita la

convergencia del proceso de optimización al mantener las entradas en una escala uniforme.

Adicionalmente, al conjunto de entrenamiento se le aplica aumento de datos mediante transformaciones aleatorias de las imágenes. Esta técnica incrementa artificialmente la diversidad del conjunto de entrenamiento sin necesidad de recolectar nuevas imágenes.

Los conjuntos de validación y prueba no reciben aumento de datos, únicamente la normalización básica. Esto es fundamental para que la evaluación refleje el desempeño real del modelo frente a imágenes no modificadas, simulando las condiciones de inferencia en producción.

3.3 Generadores de Imágenes

La carga de imágenes se realiza mediante generadores basados en `flow_from_directory`, que detectan automáticamente las clases a partir de la estructura de carpetas. Los principales parámetros de configuración de los generadores se describen a continuación:

Parámetro	Valor	Función
target_size	(150×150) / (224×224)	Redimensiona todas las imágenes a un tamaño uniforme
batch_size	32	Número de imágenes procesadas simultáneamente
class_mode	categorical	Codificación one-hot para clasificación multiclase
shuffle	True / False	Aleatorización en train; desactivado en test

4. Arquitecturas de Modelos

4.1 Primer Modelo: VGG16



El primer modelo implementado utiliza VGG16 como extractor de características. VGG16 es una arquitectura de red neuronal convolucional profunda propuesta por Simonyan y Zisserman (2014), caracterizada por su diseño regular basado en bloques de capas convolucionales de 3×3 seguidas de capas de max-pooling. El modelo fue preentrenado sobre el conjunto ImageNet, que contiene más de 1.2 millones de imágenes distribuidas en 1 000

categorías, lo que le confiere una representación visual general robusta.

En el contexto del Transfer Learning, la base convolucional de VGG16 se congela durante el entrenamiento, actuando exclusivamente como extractor de características. Sobre esta base se añaden capas densas nuevas, una capa de aplanamiento (Flatten), una capa densa intermedia con activación ReLU y una capa de salida con cuatro neuronas y activación softmax, correspondiente a las cuatro clases emocionales.

La función de activación softmax produce un vector de probabilidades cuya suma es 1, permitiendo interpretar directamente la salida del modelo como la probabilidad de que una imagen pertenezca a cada una de las clases. La predicción final corresponde a la clase con mayor probabilidad asignada.

El modelo fue entrenado durante 10 épocas con el optimizador Adam y la función de pérdida categorical cross-entropy.



Los resultados obtenidos mostraron una precisión de validación cercana al 60 % y una precisión de prueba aproximada del 63 %. Las curvas de entrenamiento indican un proceso estable sin sobreajuste significativo, aunque con un leve underfitting, lo que motivó el desarrollo de un segundo modelo con una arquitectura más moderna.

4.2 Segundo Modelo: EfficientNetV2B0

El segundo modelo emplea EfficientNetV2B0, una arquitectura propuesta como mejora de la familia EfficientNet original. EfficientNetV2 introduce bloques de convolución fusionada en las capas iniciales y aplica un escalado compuesto que optimiza simultáneamente la profundidad, el ancho y la resolución de la red.

Componente	Función
EfficientNetV2B0 (congelado)	Extractor de representaciones visuales ricas
Global Average Pooling	Resume los mapas de características en un vector compacto
Capa Densa (256 neuronas, ReLU)	Aprende relaciones entre características y emociones
Dropout	Regularización mediante desactivación aleatoria de neuronas
Capa Densa Softmax (4 neuronas)	Produce la distribución de probabilidades sobre las 4 clases

El uso de Global Average Pooling en lugar de una capa de aplanamiento tiene como ventaja principal la reducción del número de parámetros del clasificador final, lo que disminuye el riesgo de sobreajuste y aligera el modelo. En lugar de transformar todos los mapas de activación en un vector de alta dimensionalidad, GAP resume cada mapa en un único valor escalar, su promedio espacial.

La capa de Dropout, con una tasa del 30 %, desactiva aleatoriamente una fracción de las neuronas durante cada paso de entrenamiento, obligando al modelo a desarrollar representaciones distribuidas y robustas, en lugar de depender de conexiones específicas que podrían memorizar patrones particulares del conjunto de entrenamiento.

5. Proceso de Entrenamiento

5.1 Callbacks de Entrenamiento

Para el segundo modelo se implementaron mecanismos de supervisión automática del entrenamiento mediante callbacks de Keras. Estos componentes intervienen durante el proceso de optimización para mejorar la eficiencia y la calidad del modelo resultante:

Callback	Función
EarlyStopping	Interrumpe el entrenamiento si la métrica de validación no mejora tras N épocas consecutivas, evitando el sobreajuste
ModelCheckpoint	Guarda automáticamente los pesos del modelo en el momento en que se alcanza la mejor métrica de validación
ReduceLROnPlateau	Reduce la tasa de aprendizaje por un factor definido cuando la métrica de validación se estanca durante M épocas

La combinación de estos tres callbacks permite un entrenamiento adaptativo y controlado, reduciendo la necesidad de ajuste manual del número de épocas y la tasa de aprendizaje.

5.2 Ajuste Fino (Fine-Tuning)

Tras el entrenamiento inicial con la base convolucional congelada, se aplicó un proceso de ajuste como segunda fase de entrenamiento. En este proceso se descongeló la totalidad de la base EfficientNetV2B0, pero se mantuvieron congeladas todas las capas excepto las últimas 30. Esta decisión se fundamenta en la naturaleza jerárquica de las representaciones aprendidas por las CNN.

Las capas iniciales de una CNN aprenden detectores de bajo nivel, como bordes, texturas y gradientes de color, que son universalmente útiles para cualquier dominio visual. Las capas más profundas aprenden representaciones de alto nivel específicas al dominio del preentrenamiento. Permitir el ajuste de estas capas superiores facilita que el modelo se especialice en los patrones visuales propios de las emociones caninas, como la posición de las orejas, la apertura de la boca y la tensión muscular facial.

El modelo fue recompilado con el optimizador RMSprop y una tasa de aprendizaje muy reducida (1×10^{-6}), lo que garantiza que los ajustes sobre los pesos preentrenados sean incrementales y no destruyan las representaciones previamente aprendidas. Posteriormente se realizó una segunda fase de entrenamiento de hasta 15 épocas con los mismos callbacks.

6. Evaluación y Resultados

6.1 Métricas de Evaluación

La evaluación del modelo final se realizó sobre el conjunto de prueba, que no fue expuesto al modelo durante ninguna fase del entrenamiento. Se emplearon las métricas estándar de clasificación multiclase, siguiendo la metodología del artículo de referencia siendo accuracy, precisión, recall, F1-score y la matriz de confusión

6.2 Resultados del Modelo Final

El modelo EfficientNetV2B0 con fine-tuning obtuvo los siguientes resultados en el conjunto de prueba:

	precision	recall	f1-score	support
angry	0.67	0.64	0.66	150
happy	0.61	0.77	0.68	150
relaxed	0.62	0.62	0.62	150
sad	0.83	0.65	0.73	150
accuracy			0.67	600
macro avg	0.68	0.67	0.67	600
weighted avg	0.68	0.67	0.67	600

6.3 Matriz de Confusión

La matriz de confusión proporciona una visión detallada sobre los errores de clasificación del modelo. Cada fila representa la clase real y cada columna la clase predicha. Los valores en la diagonal principal (resaltados en verde) corresponden a las predicciones correctas.

```
[[ 96  30  16   8]
 [ 14 115  18   3]
 [ 13  35  93   9]
 [ 20   9  23  98]]
```

7. Análisis e Interpretación de Resultados

El modelo alcanzó un accuracy global del 67 % en el conjunto de prueba. Para contextualizar este resultado, un clasificador aleatorio con cuatro clases balanceadas obtendría una precisión esperada del 25 %. Por lo tanto, el modelo demuestra que ha aprendido patrones visuales estadísticamente significativos asociados a las emociones caninas.

7.1 Clase con Mejor Desempeño

La clase sad obtuvo el F1-score más alto (0.73) y la precision más elevada (0.83), lo que indica que cuando el modelo predice que un perro está triste, acierta con alta frecuencia. Este comportamiento puede deberse a que la expresión visual de la tristeza en perros como orejas caídas, postura encorvada, mirada baja sea visualmente más distintiva respecto a las otras categorías.

7.2 Clase con Mayor Recall

La clase happy presentó el recall más elevado (0.77), indicando que el modelo detecta correctamente la mayor parte de los perros felices. Sin embargo, su precision es la más baja (0.61), lo que revela una tendencia del modelo a clasificar imágenes de otras clases como happy. Este fenómeno se confirma en la matriz de confusión: 35 imágenes reales de perros relajados y 30 de perros enojados fueron clasificadas incorrectamente como felices.

7.3 Principales Confusiones del Modelo

El análisis de la matriz de confusión revela dos patrones de error predominantes:

- **angry** → **happy**: 30 de 150 perros enojados fueron clasificados como felices. Esto sugiere que ciertas expresiones de excitación o tensión muscular en perros enojados pueden compartir rasgos visuales superficiales con la expresión de felicidad, especialmente en imágenes donde el contexto situacional no está disponible.
- **relaxed** → **happy**: 35 de 150 perros relajados fueron clasificados como felices. La similitud entre ambas categorías puede explicarse por la dificultad intrínseca de distinguir visualmente entre un perro tranquilo y uno contento, ya que en ambos casos la expresión facial puede ser similar.

Estos resultados son consistentes con la naturaleza subjetiva de la categorización emocional en animales y con el hecho de que las emociones intermedias representan un desafío incluso para observadores humanos.

8. Comparación con la Literatura de Referencia

El proyecto tomó como referencia el trabajo citado anteriormente, quienes compararon múltiples arquitecturas de CNN para la misma tarea de clasificación de emociones caninas. Los resultados reportados en dicho artículo y el

resultado obtenido en el presente trabajo se resumen a continuación:

Modelo / Arquitectura	Fuente	Accuracy en Prueba
CNN personalizada	Putri et al. (2023)	74.75 %
VGG16	Putri et al. (2023)	68.67 %
ResNet50	Putri et al. (2023)	65.10 %
VGG16 (Modelo 1)	Este trabajo	63 %
EfficientNetV2B0 + Fine-tuning (Mod. 2)	Este trabajo	68 %

El modelo EfficientNetV2B0 con fine-tuning alcanza un desempeño cercano al de VGG16 reportado en el artículo de referencia (68.67 %), superando además a ResNet50. Aunque no logra superar la CNN personalizada del artículo, el resultado es notable dado que EfficientNetV2B0 opera con significativamente menos parámetros que sus competidores, lo que representa una ventaja en términos de eficiencia computacional.

9. Conclusiones

El presente trabajo demostró la viabilidad de clasificar automáticamente emociones en perros a partir de imágenes utilizando técnicas de aprendizaje profundo y Transfer Learning.

Referencias

- Putri, R. A., et al. (2023). Classification of Dog Emotions Using Convolutional Neural Network Method. Disponible en: https://drive.google.com/file/d/1xbXEbpDo8rO1zZc3t9-56L_ABptaHiDW
- Shanbalico, D. (2023). Dog Emotion Dataset. Kaggle. Disponible en: <https://www.kaggle.com/datasets/danielshanbalico/dog-emotion/data>